从训练语义到本地实现对象

共享的 prompt、rollout 与 token mask 向奖励和概率计算分流；DPO 与 GRPO 使用不同的优化统计量。

