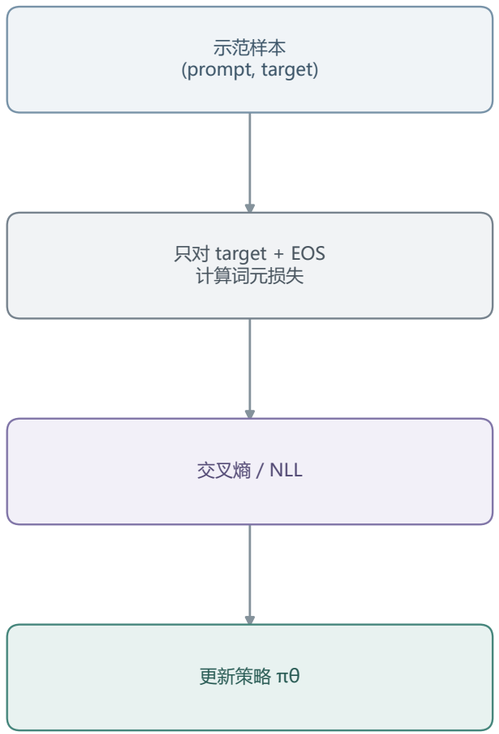
训练回路比较：数据是否更新，决定采样与反馈位置

固定示范 / 偏好对以静态样本训练；在线 DPO 与 GRPO 将策略采样和外部反馈纳入更新闭环。

SFT

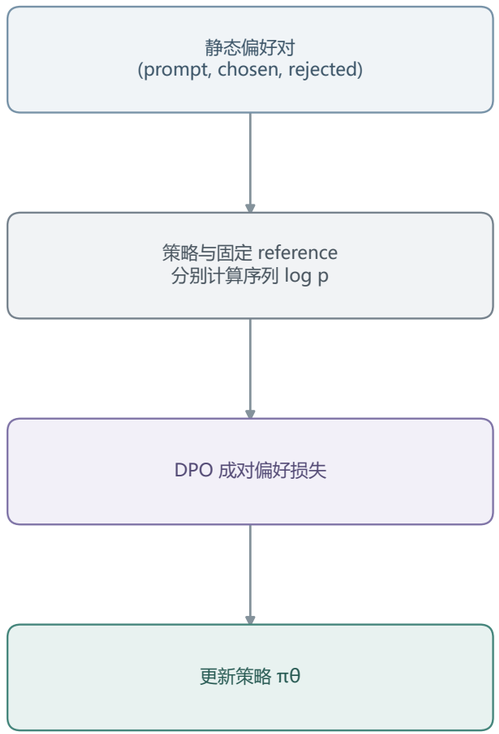
固定示范 · 监督更新



样本固定；训练仅拟合目标回答

离线 DPO

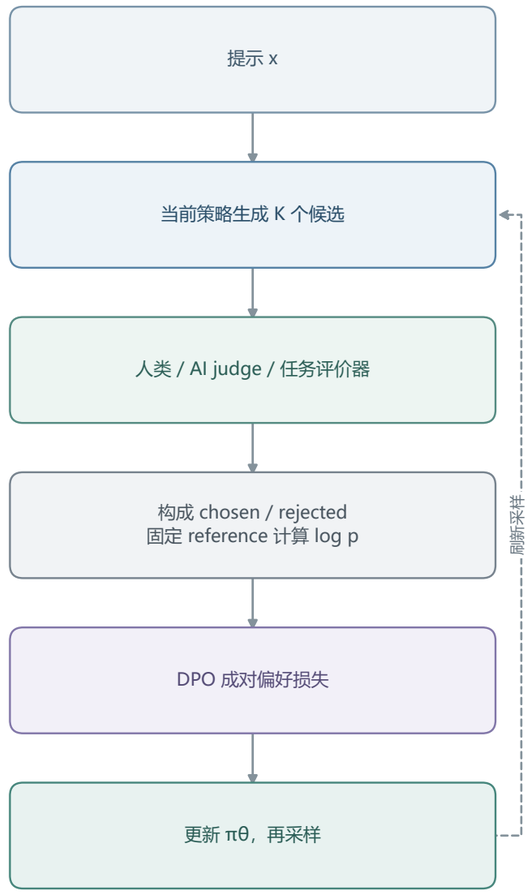
固定偏好对 · 不在线采样



reference = 固定 SFT 策略；不从模型生成新回答

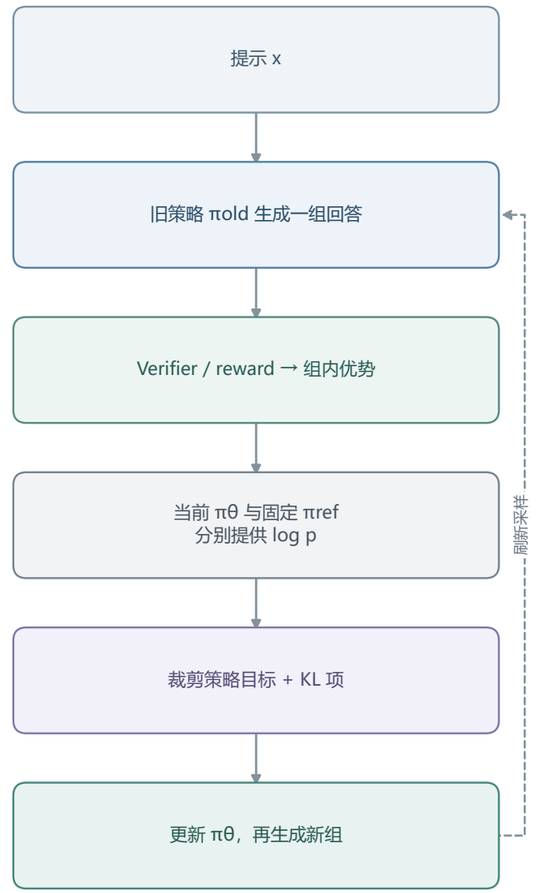
在线 DPO

当前策略采样 · 反馈后再训练



GRPO

组采样 · 在线策略优化



πold：生成 rollout 的行为策略
πref：KL 锚点；与 πold 不同