后训练反馈的监督单元、信号位置与盲区

监督粒度从完整回答延伸到偏好、推理步骤、任务结果和交互轨迹；各类信号回答的问题不同。

反馈形式	监督单元	信号进入训练的位置	需要留意的盲区
示范 / SFT [1]	提示与目标回答中的词元	训练时：对示范回答进行逐词元拟合	依赖示范覆盖；学习复现目标文本，不直接表示候选之间的相对偏好。
成对偏好 [1, 7]	同一提示下的回答对 (chosen, rejected)	候选回答完成后：提供比较标签或偏好排序	提供相对次序而非逐步修正；会受标注一致性与评判器偏差影响。
过程步骤 [22, 23]	推理轨迹中的步骤或步骤边界	生成过程中：局部判断进入 PRM 或逐步奖励	步骤标签可能有噪声；局部看似合理不保证整条推理最终正确。
结果验证 [24–26, 28]	最终答案、程序执行结果或约束满足	完整回答后：规则、测试或 verifier 返回结果信号	常为稀疏终局反馈，且只覆盖 verifier 定义的属性；可能出现奖励投机。
环境轨迹 [3, 35, 36, 40]	多轮状态、动作、观察与任务结果	交互中或任务结束后：工具、环境或现实结果回报	交互成本高、回报可能延迟；环境状态和评测设定也会限制外推。

各项为典型监督形式与机制性限制，不表示每项方法都采用相同实现。